

2026年4-8月执行计划（修订版）：MLOps / AI工程师 就业导向 + 论文产出

适用对象： Richard — Sheffield MComp AI/CS 2024毕业，申请PoliTo/Sapienza 2026秋季入学，目标毕业后在欧盟就业

核心定位： MLOps / AI应用工程师 — 欧盟缺口最大、增速最快的技术方向

三条并行线：

1. **工程能力主线（60%）：** 构建可部署的AI系统能力 → 简历项目 + 面试硬实力
2. **论文副线（20%）：** ThinkRouter研究推进 → 投Workshop/短会议 → 求职加分项
3. **基础副线（20%）：** LeetCode + 系统设计 + PoliTo预习 → 面试准备 + 入学衔接

为什么选MLOps / AI工程师？

欧盟就业数据支撑：

- 2026年全球AI人才供需比1:3.2，MLOps/LLM开发/AI伦理缺口最严重（需求85+/100，供给<35/100）
- 欧盟目标2030年2000万tech岗位，预计只有1200万人可用，缺口800万
- 德国14.9万IT空缺，平均空缺超7个月；75%欧洲雇主招不到合格技术人才
- AI/ML工程师、MLOps、Cloud/DevOps、Cybersecurity是2026年最热门的4个方向
- 企业需要的是能构建**生产级ML系统**的工程师，不是只会跑Jupyter Notebook的人

薪资预期（欧盟）：

- 意大利本地：AI工程师 €34k-44k/年（米兰）
- 德国：ML工程师 €60k-90k/年
- 远程/瑞士/爱尔兰：€80k-130k/年
- 策略：意大利读书拿居留 → 全欧盟范围求职或做远程

总体时间线

月份	工程主线	论文副线	基础副线
4月下 (W3-W4)	Docker/FastAPI基础 + 原计划收口	ThinkRouter实验继续	LeetCode启动
5月	MLOps Pipeline + 模型 Serving	ThinkRouter论文初稿	LeetCode + Comp Arch预习
6月	Cloud (AWS/GCP) + RAG 系统	论文投稿 + 迭代	LeetCode + System Design
7月	LLM Agent项目 + CI/CD	论文修改/二投	系统设计 + SDP预习
8月	综合项目收口 + 简历优化	论文收尾	面试模拟 + 预习收口

4月下半 (W3-W4)：过渡期 — 原计划收口 + 新方向启动

目标

- 完成原计划W3-W4的GPU/KV Cache内容（不浪费已有进度）
- 同时启动Docker和FastAPI基础（工程转型第一步）
- 开始每日LeetCode

每日安排

时间块	内容	时长
上午	原计划W3-W4内容（GPU profiling、KV Cache实验）	3-4h
下午前半	Docker入门 + FastAPI入门	2h
下午后半	LeetCode 1-2题（从Easy开始，Python）	1h
晚上	ThinkRouter实验（API调用跑benchmark）	1-1.5h

W3-W4具体任务

工程新增（每天2h）：

- Day 1-2: Docker基础 — 安装Docker, 理解image/container/Dockerfile/docker-compose, 把一个Python脚本容器化
- Day 3-4: FastAPI基础 — 写一个简单的REST API (POST接收文本, 返回处理结果), 理解路由/请求/响应/async
- Day 5-6: Docker + FastAPI结合 — 把FastAPI应用容器化, docker-compose启动
- Day 7: 用FastAPI包装一个HuggingFace模型推理 (text-generation pipeline), Docker部署

LeetCode (每天1h) :

- 第1周: 数组/字符串 Easy 7题 (Two Sum、Valid Palindrome等经典)
- 第2周: 哈希表/双指针 Easy-Medium 7题
- 工具: LeetCode + NeetCode路线图

论文副线 (每晚1-1.5h) :

- 继续跑ThinkRouter的MATH-500和MMLU STEM实验
- 整理已有的pilot数据 (GSM8K ~2% gap、MMLU 0% gap、MATH L5 ~11% gap)

W3-W4结束时应拿到

- 能用Docker容器化一个FastAPI模型服务
- LeetCode完成14题
- ThinkRouter实验数据进一步积累
- 原计划GPU/KV Cache内容完成 (不浪费)

5月: MLOps Pipeline + 模型Serving + 论文初稿

5月目标

工程主线 (60%) :

- 搭建完整的MLOps pipeline: 数据→训练→评估→部署→监控
- 学会用vLLM/TGI做模型serving
- 掌握MLflow实验追踪
- GitHub上有一个完整的端到端项目

论文副线（20%）：

- 完成ThinkRouter所有benchmark实验
- 写出论文初稿（targeting workshop deadline）

基础副线（20%）：

- LeetCode累计50+题
- Computer Architectures预习开始

5月周计划

W5-W6（5/1-5/11）：MLOps基础 + 实验追踪

日期	工程主线（4-5h）	论文（1.5h）	基础（1-1.5h）
5/1	MLflow入门：安装，记录实验（参数、指标、模型artifact）	MATH-500 Level 3-4实验	LC 2题
5/2	MLflow实战：用MLflow追踪一个sklearn模型训练过程	续	LC 2题
5/3	Weights & Biases入门：对比MLflow和W&B的workflow	整理实验数据到表格	公众号输出
5/4	HuggingFace模型fine-tuning基础（LoRA/QLoRA概念）	HumanEval实验	LC 2题 + CA预习
5/5	用PEFT库做一个小模型的LoRA fine-tune实验	续	LC 2题 + CA预习
5/6	Fine-tune + MLflow：完整记录训练过程	MT-Bench实验	LC 2题
5/7	Docker化整个训练pipeline	实验数据汇总	LC 1题 + CA预习
5/8	闭卷回忆MLOps概念 + 整理笔记	开始写论文Related Work	CA预习
5/9	休息/公众号输出	—	—

W7-W8（5/12-5/25）：模型Serving + 部署

	工程主线（4-5h）		基础（1-
--	------------	--	-------

日期		论文 (1.5h)	1.5h)
5/12	vLLM入门：安装，用vLLM serving一个开源模型（Qwen-2等）	写Methodology	LC 2题
5/13	vLLM深入：理解continuous batching、PagedAttention（概念层面）	续	LC 2题 + CA
5/14	TGI（Text Generation Inference）对比：部署同一个模型	写Experimental Setup	LC 2题
5/15	Benchmark：vLLM vs TGI吞吐量/延迟对比	续	LC 1题 + CA
5/16	FastAPI + vLLM：写一个production-ready的推理API	写Results初稿	LC 2题
5/17	加Prometheus监控 + Grafana dashboard（模型serving监控）	续	公众号输出
5/18	Docker-compose：FastAPI + vLLM + Prometheus + Grafana 一键启动	Results数据可视化	LC 2题 + CA
5/19	Nginx反向代理 + 负载均衡基础	写Introduction	LC 1题
5/20	项目整理：README、架构图、部署文档	续	CA预习
5/21	推到GitHub：llm-serving-pipeline项目	论文初稿整合	LC 2题
5/22	写技术博客：发公众号/知乎	内部review初稿	LC 1题 + CA
5/23	缓冲/补漏	论文初稿完成	整理LC笔记

5月结束时应拿到

工程：

- GitHub项目：llm-serving-pipeline（FastAPI + vLLM + Docker + 监控）
- 能完整描述MLOps lifecycle
- MLflow/W&B实验追踪实操经验

论文：

- ThinkRouter论文初稿完成

- 所有benchmark数据收集完毕

基础：

- LeetCode 50+题
- Computer Architectures核心概念笔记

6月： Cloud平台 + RAG系统 + 论文投稿

6月目标

工程主线（60%）：

- 掌握AWS或GCP基础（EC2/S3/Lambda 或 Compute/Storage/Cloud Functions）
- 构建一个完整的RAG系统（向量数据库 + Embedding + LLM）
- 学会Kubernetes基础部署

论文副线（20%）：

- 投稿一个Workshop或短会议
- 根据反馈迭代

基础副线（20%）：

- LeetCode累计80+题，开始Medium为主
- System Design基础

6月周计划

W9-W10（6/1-6/14）： Cloud + RAG

主题	具体内容
Cloud基础（4天）	AWS Free Tier注册；EC2启动GPU实例部署模型；S3存储模型artifact；IAM权限管理基础
RAG系统搭建（6天）	ChromaDB/Weaviate向量数据库；文档切分（LangChain text splitter）；Embedding模型选型（OpenAI/开源）；检索+生成pipeline；评估（Ragas框架）；FastAPI封装成服务
论文（并	

行)	投稿前最终修改；格式调整；投稿
LeetCode	每天1-2题Medium

W11-W12 (6/15-6/28) : K8s基础 + RAG项目完善

主题	具体内容
Kubernetes (4天)	Minikube本地K8s；Pod/Service/Deployment概念；用K8s部署5月的llm-serving-pipeline；Helm chart基础
RAG项目完善 (4天)	加入Reranker；Hybrid Search (dense+sparse) ；Streaming输出；部署到AWS/GCP
项目收口 (2天)	rag-pipeline推到GitHub；写技术博客
System Design	每周看1个系统设计case（推荐：Alex Xu的System Design Interview）

6月结束时应拿到

工程：

- GitHub项目：rag-pipeline（向量DB + Embedding + LLM + Reranker + Cloud部署）
- AWS/GCP基础操作能力
- Kubernetes基本部署能力

论文：

- ThinkRouter已投稿
- 等待review或已收到反馈

基础：

- LeetCode 80+题
- System Design基础概念

7月：LLM Agent项目 + CI/CD + 论文迭代

7月目标

工程主线（60%）：

- 构建一个多工具LLM Agent系统（核心项目，面试重点讲）
- 学会CI/CD pipeline（GitHub Actions）
- 掌握测试（pytest + 集成测试）

论文副线（20%）：

- 根据review反馈修改论文
- 如被拒，改投其他venue

基础副线（20%）：

- System Design为主
- PoliTo SDP预习（C++多线程基础）

7月核心项目：LLM Agent系统

项目定义： 一个能调用多种工具（Web搜索、代码执行、数据库查询、文件操作）的LLM Agent，支持多轮对话和工具链式调用。

周	工程任务
W13	Agent框架选型（LangGraph vs CrewAI vs 自研）；实现单工具Agent（web search）；理解ReAct/Function Calling模式
W14	多工具Agent：加入code interpreter、SQL查询；实现工具链（Tool A输出→Tool B输入）；错误处理和重试机制
W15	生产化：加入对话记忆（Redis/PostgreSQL）；Streaming输出；用户认证（JWT）；Rate limiting
W16	CI/CD：GitHub Actions自动测试+部署；pytest单元测试+集成测试；Docker build→push→deploy pipeline；项目收口+文档+博客

7月结束时应拿到

工程：

- GitHub项目：llm-agent-system（多工具Agent + CI/CD + 测试 + 部署）
- 三个完整GitHub项目组成作品集
- CI/CD实操经验

论文：

- 修改版提交或二投

8月：综合收口 + 简历 + 面试准备

8月目标

- 三个项目全部polish到可展示状态
- 简历/LinkedIn优化
- 面试模拟（技术+行为）
- PoliTo预习收口
- 意大利语启动

8月周计划

周	主要任务
W17	项目补漏：每个项目补充README、架构图、性能数据；确保Docker一键启动
W18	简历优化：按STAR格式写项目描述；LinkedIn更新；GitHub Profile README
W19	面试准备：System Design模拟（设计一个LLM serving系统）；行为面试STAR故事准备；LeetCode复习高频题
W20	综合收口：PoliTo预习笔记整理+自测；意大利语入门（Duolingo启动）；8月mini report

8月结束时应拿到

- 3个production-grade GitHub项目
 - 1篇论文（已投或已发表）
 - LeetCode 100+题
 - 简历和LinkedIn就绪
 - PoliTo核心课预习完成
 - 准备好9月入学
-

GitHub项目作品集规划

项目	技术栈	展示能力
llm-serving-pipeline	vLLM + FastAPI + Docker + Prometheus + Grafana	模型部署、监控、容器化
rag-pipeline	LangChain + ChromaDB + Embedding + AWS/GCP + K8s	RAG系统、Cloud、编排
llm-agent-system	LangGraph + Multi-tool + Redis + CI/CD + pytest	Agent开发、生产化、测试

这三个项目覆盖了MLOps/AI工程师面试中90%的技术话题。

每日固定产出

产出	频率
GitHub提交	每天
LeetCode	每天1-2题
公众号/知乎文章	每周1篇
论文进度	每天1-1.5h
技术笔记	每天

技能树Checklist（8月底前全部打勾）

工程能力

- Python（FastAPI、async、pytest）
- Docker + Docker Compose
- Kubernetes基础（Pod、Service、Deployment、Helm）
- AWS或GCP（EC2/S3/Lambda基础操作）

- MLflow / Weights & Biases
- vLLM / TGI 模型serving
- LangChain / LangGraph
- 向量数据库 (ChromaDB/Weaviate)
- CI/CD (GitHub Actions)
- Prometheus + Grafana监控
- Git工作流 (分支管理、PR、Code Review)
- SQL基础

算法与系统设计

- LeetCode 100+题 (数组、哈希、双指针、二叉树、图、DP基础)
- 系统设计: 设计一个LLM serving系统
- 系统设计: 设计一个RAG pipeline
- 系统设计: 设计一个实时推荐系统

论文与研究

- ThinkRouter论文完成并投稿
- 至少1次conference/workshop review经历

PoliTo预习

- Computer Architectures: 流水线、缓存、分支预测、虚拟内存
- System Programming: C/C++基础、多线程概念
- 意大利语Duolingo启动

关键里程碑

- 4/27 — Docker + FastAPI基础完成, LeetCode 14题
- 5/25 — llm-serving-pipeline上线GitHub, 论文初稿完成, LeetCode 50题
- 6/28 — rag-pipeline上线GitHub, 论文已投稿, LeetCode 80题

- 7/26 — llm-agent-system上线GitHub, 论文修改版提交, 系统设计准备就绪
 - 8/24 — 简历/LinkedIn就绪, 面试准备完成, 预习收口
 - 8/31 — 准备好入学PoliTo/Sapienza
-

最后更新: 2026年4月14日